

VISIÓN ARTIFICIAL

Sistemas de Visión por Computador Distribuida para Gestión y Control basados en Arquitecturas AIoT

Materia: Visión Artificial

Docente: González, Alexis

Alumnos

Casali, Emiliano

Del Soto, Juan Gustavo

Ferrero, Facundo José

Vera, Cristian Gonzalo



Agenda

1

Introducción

El cambio de paradigma: de la visión centralizada a la distribuida

2

Marco teórico

La arquitectura Edge-Fog-Cloud y los 4 ejes de análisis

3

Aplicación en la industria

Cuatro dominios: Industrial, Tráfico, Ambiental, Agrícola

4

Casos de estudio

Resultados reales de cada dominio


5

Conclusión y futuras direcciones

Una arquitectura, múltiples soluciones

De la visión centralizada a la visión distribuida

- Modelo tradicional: cámaras pasivas que transmiten a un servidor central — no escala con el volumen de datos ni depende de conectividad permanente
- Procesadores embebidos con NPU/GPU permiten ejecutar inferencia directamente en el dispositivo de captura
- Modelos livianos (YOLO-nano, MobileNet, EfficientDet-Lite) habilitan tiempo real en hardware de bajo consumo
- Protocolos livianos (MQTT/TLS, gRPC, SRT) transmiten eventos estructurados, no video crudo
- La visión por computador deja de ser un problema algorítmico: ahora es un problema de infraestructura distribuida




Cuatro ejes de análisis: el hilo conductor



- Poder de cómputo: qué hardware y software se despliega en cada nivel
- Latencia: qué protocolos transportan el dato, bajo qué restricciones temporales
- Inteligencia artificial: qué tipo de inferencia se ejecuta en cada nivel
- Seguridad: cómo se protege el dato visual de extremo a extremo
- Estos 4 ejes se aplican sistemáticamente a Edge, Fog y Cloud — y organizan toda esta presentación

De la imagen digital a la decisión

- La imagen es una matriz de píxeles: resolución, profundidad de bits y formato condicionan todo el sistema (1920×1080 RGB @30fps ≈ 186 MB/s)
- El procesamiento clásico (binarización, morfología, filtrado, segmentación) sigue vigente como preprocesamiento
- Las CNN aprenden qué características extraer: LeNet → AlexNet → ResNet → MobileNet
- Detección en tiempo real: familia YOLO y RT-DETR
- Segmentación con U-Net y modelos fundacionales (SAM); OCR con pipeline detector + reconocedor



Arquitectura Edge-Fog-Cloud: tres perfiles complementarios



- Edge: latencia mínima, cómputo limitado — percepción en el borde
- Fog: capa intermedia — integración, coordinación y autonomía local
- Cloud: cómputo elástico, latencia alta — entrenamiento y supervisión multi-sitio
- Estándares de referencia: NIST SP 500-325 (fog) e IEEE 1934 / OpenFog (8 pilares arquitectónicos)
- Cada nivel debe resolver simultáneamente: cómputo, latencia, IA y seguridad


Los 4 ejes aplicados a cada capa

	EDGE	FOG	CLOUD
Cómputo	Hardware específico: Jetson, RK3588, ESP32-S3	El SO abstrae el hardware: Linux + Docker	Capacidad elástica por API (GPU A100/H100)
Latencia	8-15 ms inferencia; <10 ms MQTT	5-50 ms interno; buffering ante cortes	Segundos (dashboards) a días (reentrenamiento)
Inteligencia Artificial	Percepción: YOLOv8n, MobileNet, modelos cuantizados	Validación, correlación y re-inferencia	Entrenamiento, MLOps, detección de drift
Seguridad	TPM, Secure Boot, mTLS	VLAN, ACLs en MQTT, Docker secrets	IAM, MFA, SIEM, Ley 25.326

Lectura transversal: el cómputo decrece y la latencia crece de Edge a Cloud; la IA cambia de naturaleza en cada capa; la seguridad está presente en todas, con un foco distinto en cada una.

Cómo funciona el sistema completo

- Estación de percepción Edge: GStreamer, preprocesamiento, inferencia en cascada, grabación y autonomía energética
- Núcleo operacional Fog: broker MQTT, correlación (Node-RED/Redis), motor de actuación, dashboard local
- Inteligencia estratégica Cloud: dashboard global, reentrenamiento (DVC/MLflow), distribución OTA
- Actuación distribuida: microcontroladores suscriptos a MQTT — percepción y actuación desacopladas
- Resiliencia: sin punto único de falla — cada capa sigue operando si la superior cae




A CONTINUACIÓN

Inspección visual en línea de producción

Emiliano Casali


Industrial: qué se detecta y qué modelos se aplican



- Defectos superficiales, nivel de llenado, posición de etiquetas, calidad de soldadura, contaminantes
- Cascada de modelos: YOLO (localización) → U-Net (segmentación fina) → PatchCore (anomalías sin ejemplos de falla)
- PatchCore es clave en manufactura: los eventos anómalos son infrecuentes y variables
- El nodo Edge ejecuta la cascada completa antes de notificar al Fog

Integración con el piso de planta

- Actuadores: reector en línea, señal al PLC para detener la banda, clasificación OK/NOK
- OPC UA hacia PLC/SCADA para el lazo de control
- MQTT/Sparkplug hacia MES para trazabilidad de producción
- OPC UA Vision (OPC Foundation) conecta visión con PLC, MES, SCADA, ERP y nube sin rehacer la pirámide de automatización




Industrial: beneficios y desafíos



Beneficios: reducción de scrap, trazabilidad completa, inspección 24/7 a velocidad superior a la humana

Desafíos: iluminación variable, drift por cambio de lote, PLCs legacy, certificación IEC 62443 / NIST SP 800-82

Caso de estudio: inspección visual en línea de producción



- Transformación de un sistema modular hacia arquitectura con MES + Fog + nube
- Visión con OpenCV: clasificadores en cascada, análisis HSV, detección de bordes Canny
- Flujo: cámara → preprocesamiento/clasificación OK-NOK → evento MQTT al Fog → registro y sincronización con MES → orden al actuador
- Integración sobre activos legacy mediante señales AS-i

Resultados — Caso Industrial

~30%

Mejora en tiempos de espera y
reabastecimiento

100%

Inspección en línea, clasificación
inmediata


24/7

Operación continua sin fatiga del
operador

Fuente: arquitectura con MES, fog computing y visión OpenCV (clasificadores en cascada, HSV, Canny)

Inspección manual vs. distribuida

- Manual: subjetiva, lenta, sujeta a fatiga, sin trazabilidad digital
- Distribuida: inspección 100% en línea con clasificación inmediata
- Sincronización automática con stock y órdenes de producción
- Arquitectura escalable a otras funciones OT/IT sin multiplicar interfaces propietarias



A CONTINUACIÓN

Gestión de Tráfico y Seguridad Vial

Gonzalo Vera

Gestión de tráfico: percepción en la vía pública

- Dos subproblemas: control adaptativo local en intersecciones + seguimiento distribuido multi-intersección
- Objetos detectados: vehículos, peatones, bicicletas, motos, ocupación de carril, congestión, infracciones
- Modelos: YOLO (detección de vehículos), ByteTrack (tracking y conteo), OCR (lectura de patentes)



Actuación: del dato visual a la decisión semafórica



- Lógica adaptativa de semáforos, con el tamaño de cola como parámetro de control
- Paneles informativos viales con estado del tráfico en tiempo real
- Alertas a autoridades de tránsito ante incidentes
- Las decisiones se ejecutan localmente, dentro del gabinete semafórico (Edge)

Tráfico: beneficios y desafíos




Beneficios: menor congestión, menores tiempos de viaje, detección temprana de incidentes, datos para planificación urbana

Desafíos: clima adverso, reflejos nocturnos, oclusión entre vehículos, escala de nodos, privacidad vehicular

Caso de estudio: gestión inteligente de tránsito urbano

- Edge: gabinete semafórico con cámara y procesador — inferencia 100% local
- Fog: centro de control de tránsito, coordinación de corredores
- Cloud: telemetría, auditoría y optimización de red
- WatchDog: reidentificación distribuida con retrasos <4 min incluso en hora pico
- Smart intersection: modelo optimizado con 93.64% de precisión y 97.8% de compresión



Resultados — Caso Tráfico

18-32%

Reducción del retraso medio por
vehículo

+50-200

Vehículos/hora adicionales en accesos
cargados

100%

Operación continua durante cortes de
backhaul

Fuente: controlador adaptativo basado en cámaras en gabinete semafórico, cómputo completamente local

Semáforos pretemporizados vs. visión distribuida



Tradicional: ciclos fijos y lazos inductivos — no observan colas, giros ni peatones

Distribuida: observa el contexto completo y ajusta los ciclos en tiempo real

A CONTINUACIÓN

Monitoreo Ambiental y Gestión de Emergencias

Facundo Ferrero

Monitoreo ambiental: detección temprana de siniestros



- Eventos: humo, fuego, inundaciones, derrumbes, nivel de agua, contaminación visible, clima adverso
- Modelos: clasificación binaria (humo/fuego), segmentación de área afectada, detección de cambio temporal
- Desafío de campo: nodos a panel solar y batería, conectividad intermitente, operación offline-first

Actuación: de la detección a la respuesta de emergencia

- Sirena de alerta local
- Notificación a defensa civil
- Notificación push geolocalizada a dispositivos en la zona afectada
- Activación de protocolos de evacuación



Ambiental: beneficios y desafíos



Beneficios: menor tiempo de respuesta, cobertura de zonas extensas, trazabilidad post-evento

Desafíos: falsos positivos por nubes/neblina/vapor, condiciones extremas, autonomía energética, vandalismo

Caso de estudio: detección de incendios forestales (ALERTCalifornia)



- Red de más de 1.000 cámaras PTZ HD con barridos de 360° cada 2 minutos
- Visión nocturna infrarroja, alcance de hasta 60 millas de día
- IA de detección temprana alerta con localización y certeza a 21 centros de despacho de CAL FIRE
- WIFIRE genera mapas predictivos de propagación en minutos

Resultados — Caso Ambiental

>1.200

Incendios detectados en la primera
temporada operativa

>30%


De los casos adelantados al reporte al
911

42 min

Detección 5:19 → llamada 6:01,
contención <1/4 acre

Fuente: ALERTCalifornia (UC San Diego / CAL FIRE) y sistema WIFIRE de modelado predictivo

Vigilancia humana vs. detección asistida por IA



Tradicional: torres y reportes telefónicos, dependientes de la atención sostenida de operadores

Con IA: detección automática + modelado de propagación cambia la cronología de respuesta

A CONTINUACIÓN

Agricultura de Precisión

Gustavo del Soto

Agricultura de precisión: percepción sobre el cultivo

- Detección: plagas, malezas, enfermedades foliares, madurez de frutos, estrés hídrico, densidad de siembra
- Modelos: YOLO (plagas/malezas), clasificación (enfermedades), segmentación, análisis multiespectral
- Drones como nodos Edge móviles: inferencia local y mapas geolocalizados



Actuación: del mapa de detecciones a la acción en el lote



- Inyección selectiva de fumigación solo en zonas afectadas
- Control de riego por zona
- Ajuste de fertilización variable
- El Fog correlaciona los mapas del dron para planificar la actuación


Agricultura: beneficios y desafíos



Beneficios: menos agroquímicos, precisión de tratamiento, trazabilidad, optimización hídrica

Desafíos: iluminación exterior variable, polvo en lentes, autonomía de vuelo, conectividad rural, datasets específicos

Caso de estudio: fumigación selectiva (John Deere See & Spray + FarmBeats)



- Cámaras en la barra identifican malezas en milisegundos, con disparo en ventana de 200 ms
- Boquillas ExactApply se activan solo donde se detectó maleza
- Frontera Edge/Fog ubicada in-cab / in-machine
- FarmBeats: gateway de granja con operación independiente y compresión 1000× de video aéreo

Resultados — Caso Agrícola

77%

Ahorro de herbicida en barbecho
(75.000 acres evaluados)

>50%


Reducción de volumen en maíz, algodón
y soja

+30%

Mejora en área cubierta por vuelo
(FarmBeats)

Fuente: John Deere See & Spray™ y Microsoft FarmBeats

Pulverización broadcast vs. visión distribuida



Broadcast: trata el lote como homogéneo y aplica uniformemente

Distribuida: inferencia y filtrado en la máquina/gateway; la nube conserva historial y orquestación

A CONTINUACIÓN

Síntesis y Cierre

Todo el equipo

Conclusión: una arquitectura, múltiples dominios

- Hallazgo central: Edge-Fog-Cloud es una base reutilizable si se diseña como arquitectura adaptable, no como aplicación cerrada
- Lo que permanece: percepción local, coordinación intermedia, inteligencia estratégica y actuación distribuida
- Lo que cambia entre dominios: el modelo de IA, las reglas operacionales y los actuadores
- Futuras direcciones: active/federated learning, foundation models, gemelos digitales, OPC UA FX/TSN y computación ubicua



Referencias

- [1] J. Redmon et al., "You Only Look Once: Unified, Real-Time Object Detection," IEEE CVPR, 2016.
- [2] M. Sandler et al., "MobileNetV2," IEEE CVPR, 2018.
- [4][5] K. Roth et al. / P. Bergmann et al., PatchCore y MVTec AD, IEEE CVPR, 2019-2022.
- [9] OPC Foundation, "OPC UA for Machine Vision," Companion Specification, 2022.
- [10] Sistema de producción modular con MES, fog computing y visión OpenCV.
- [11] NIST SP 800-82 Rev. 3 / ISA-IEC 62443, Seguridad OT.
- [12] Controlador adaptativo en gabinete semafórico, El Salvador City.
- [13] WatchDog: reidentificación distribuida, Shenzhen.
- [14] Smart intersection deployment, Pyeongtaek, 93.64% precisión.
- [15][16] ALERTCalifornia, UC San Diego / CAL FIRE.
- [17] Sistema de detección de fuego y humo sobre Raspberry Pi 5, 97.98% exactitud.
- [18][19] John Deere See & Spray™ / Ultimate.
- [20][21] D. Vasisht et al., "FarmBeats," USENIX NSDI, 2017.
- [22] NIST SP 500-325, "Fog Computing Conceptual Model," 2018.
- [23] IEEE 1934-2018, OpenFog Reference Architecture.
- [25] Ultralytics, "YOLOv8 Documentation," 2023-2025.
- [26] Y. Zhao et al., "RT-DETR," arXiv:2304.08069, 2023.