


Universidad Tecnológica Nacional

Facultad Regional Córdoba

Licenciatura en Automatización y Control



Sistemas de Visión por Computador Distribuida para Gestión y Control basados en Arquitecturas AIoT

Materia: Visión Artificial

Docente: González, Alexis

Alumnos:

Casali, Emiliano

Del Soto, Juan Gustavo

Ferrero, Facundo José

Vera, Cristian Gonzalo

Córdoba, Argentina — 2026

Índice

Índice	2
1. Resumen (Abstract)	4
2. Introducción	5
3. Marco Teórico	7
3.1 La imagen digital como dato de ingeniería	7
3.2 Procesamiento clásico de imágenes	7
3.3 Redes neuronales convolucionales y modelos de detección, segmentación y OCR	9
3.4 Arquitectura Edge-Fog-Cloud para visión distribuida	10
3.5 Ejes de análisis: cómputo, latencia, inteligencia artificial y seguridad	11
3.5.1 Análisis por áreas telecomputacionales	11
3.5.2 Análisis por características transversales	13
4. Desarrollo del Tema	15
4.1 Revisión de la literatura	15
4.2 Tecnologías y métodos	15
4.3 Implementación y desarrollo	15
4.3.1 Descripción funcional del sistema	15
4.3.2 Estación de percepción en Edge	15
4.3.3 Núcleo operacional en Fog	17
4.3.4 Inteligencia estratégica en Cloud	17
4.3.5 Interfaces de control y presentación	18
4.3.6 Actuación distribuida	19
4.3.7 Resiliencia y operación degradada	19
4.3.8 Seguridad transversal	19
4.3.9 Despliegue multi-dominio	19
4.3.10 Métricas de validación	19
5. Aplicación en la Industria	21
5.1 Automatización industrial y control de calidad	21
5.2 Gestión de tráfico y seguridad vial	22
5.3 Monitoreo ambiental y gestión de emergencias	22
5.4 Agricultura de precisión	23
6. Casos de Estudio	25
6.1 Caso de estudio: Inspección visual en línea de producción	25
6.2 Caso de estudio: Gestión inteligente de tránsito urbano	25
6.3 Caso de estudio: Detección de incendios forestales con visión distribuida	26
6.4 Caso de estudio: Fumigación selectiva con drones y visión artificial	26

6.5 Síntesis comparativa	27
7. Conclusión y Futuras Direcciones.....	28
8. Referencias.....	29

1. Resumen (Abstract)

El presente trabajo de investigación aborda el diseño y la implementación de una infraestructura informática distribuida orientada a la gestión y el control de procesos mediante visión artificial, bajo el paradigma AIoT (Artificial Intelligence of Things). El problema central analizado es la necesidad de procesar grandes volúmenes de datos visuales en tiempo real con baja latencia y alta confiabilidad, superando las limitaciones de los modelos puramente centralizados (Cloud) o puramente locales (Edge).

Se propone un modelo de arquitectura en tres capas (Edge, Fog y Cloud) donde la inferencia visual se distribuye dinámicamente según requisitos de poder de cómputo y criticidad temporal. Como caso de aplicación general, se analiza cómo la misma infraestructura base se adapta a cuatro dominios operacionales: automatización industrial y control de calidad, gestión de tráfico y seguridad vial, monitoreo ambiental y gestión de emergencias, y agricultura de precisión.

Se concluye que la distribución de la inferencia visual en el borde reduce latencia y consumo de ancho de banda, habilita operación autónoma ante pérdida de conectividad, y permite reutilizar la misma arquitectura en múltiples dominios de aplicación sin modificar su estructura. Lo que cambia entre dominios es el modelo de IA, las reglas operacionales y los actuadores, no la infraestructura.

2. Introducción

La visión por computador aplicada a la automatización y el control ha experimentado una transformación estructural en la última década. Los sistemas tradicionales operaban bajo un paradigma centralizado: cámaras pasivas capturaban imágenes que se transmitían a un servidor central para su procesamiento. Este modelo fue funcional mientras el volumen de datos visuales era manejable y la conectividad permanente estaba garantizada. Ninguna de esas dos condiciones se sostiene en los sistemas actuales.

La convergencia de tres factores tecnológicos alteró el escenario. Primero, la aparición de procesadores embebidos con capacidad de inferencia de redes neuronales (NPU, GPU embebidas, aceleradores dedicados) permitió ejecutar modelos de visión directamente en el dispositivo de captura, sin depender de un servidor remoto. Segundo, la maduración de modelos de detección y reconocimiento optimizados para recursos limitados (arquitecturas como YOLO-nano, MobileNet, EfficientDet-Lite) hizo viable la inferencia visual en tiempo real sobre hardware de bajo consumo y costo. Tercero, los protocolos de comunicación livianos y seguros (MQTT sobre TLS, gRPC, SRT) habilitaron la transmisión eficiente de eventos estructurados entre nodos distribuidos, sin necesidad de mover la imagen cruda completa por la red.

Estos tres factores no operan de manera aislada. Configuran un espacio de diseño donde cada decisión técnica involucra simultáneamente múltiples dimensiones: la capacidad de procesamiento disponible en cada punto de la infraestructura, la latencia admisible entre la captura y la respuesta, el tipo y profundidad de inteligencia artificial que se despliega en cada nivel, y los mecanismos de seguridad que protegen el dato visual desde su origen hasta su destino.

El análisis que sigue adopta una estructura basada en esta observación. En lugar de tratar la visión por computador como un problema exclusivamente algorítmico, se examina como un problema de infraestructura distribuida donde el dato visual atraviesa múltiples niveles de procesamiento — desde el dispositivo de captura en el borde, pasando por nodos intermedios de integración y lógica operacional, hasta la infraestructura centralizada de almacenamiento, analítica y entrenamiento.

Para organizar este recorrido se proponen cuatro ejes de análisis que se aplican sistemáticamente a cada nivel de la infraestructura: poder de cómputo, latencia, inteligencia artificial y seguridad. Esta estructura permite que cada tecnología, protocolo o decisión de

diseño se evalúe no como pieza aislada sino como componente de un sistema donde las cuatro dimensiones coexisten y se condicionan mutuamente.

3. Marco Teórico

A continuación se abordan los fundamentos de visión artificial desde la imagen digital hasta la percepción distribuida, así como los conceptos referidos a las áreas telecomputacionales Edge, Fog y Cloud respecto de los cuatro ejes de análisis del sistema.

3.1 La imagen digital como dato de ingeniería

Todo sistema de visión artificial opera sobre un objeto matemático concreto: una matriz bidimensional de valores numéricos que representan intensidades luminosas captadas por un sensor. Cada elemento de esa matriz es un píxel, y su valor depende del modelo de color utilizado: un escalar en escala de grises, una terna en RGB, o una cuádrupla en RGBA. La resolución de la imagen (cantidad de píxeles por eje), la profundidad de bits (niveles de cuantización por canal) y el formato de almacenamiento (JPEG con compresión con pérdida, PNG sin pérdida, BMP sin compresión) determinan conjuntamente el volumen de datos que el sistema debe procesar, transmitir y almacenar.

Esta caracterización no es trivial cuando la imagen deja de procesarse en un único equipo y pasa a moverse entre nodos distribuidos. Una imagen de 1920×1080 píxeles a 8 bits por canal en RGB ocupa 6.2 MB sin comprimir. A 30 frames por segundo, el stream crudo genera 186 MB/s — casi 1.5 Gbps. Este volumen condiciona toda la arquitectura posterior: qué se procesa localmente, qué se transmite, con qué protocolo, con qué compresión y con qué latencia admisible.

La adquisición impone restricciones adicionales. La óptica del sistema (distancia focal, apertura, profundidad de campo) determina qué porción de la escena es captada con nitidez suficiente para que los algoritmos posteriores funcionen. La iluminación es el factor más crítico en aplicaciones industriales: una variación de iluminación no controlada puede degradar la precisión de un sistema de detección más que un cambio de modelo de red neuronal. Estos factores — resolución, formato, óptica, iluminación — son previos a cualquier algoritmo y condicionan su desempeño de manera determinante.

3.2 Procesamiento clásico de imágenes

Antes de la irrupción del aprendizaje profundo, la visión artificial se construyó sobre un conjunto de operaciones matemáticas sobre la matriz de píxeles que siguen siendo fundamentales en cualquier pipeline moderno, incluso los basados en redes neuronales.

La binarización y umbralización convierten la imagen en una representación de dos estados (objeto/fondo) mediante la comparación de cada píxel contra un valor umbral. Los métodos adaptativos (como Otsu) calculan el umbral óptimo a partir del histograma de la imagen, lo que los hace robustos ante variaciones de contraste. Esta operación es frecuentemente el primer paso en segmentación industrial.

Las operaciones morfológicas — erosión, dilatación, apertura, cierre — actúan sobre imágenes binarias para eliminar ruido, separar objetos conectados, rellenar huecos y refinar contornos. Se basan en un elemento estructurante que recorre la imagen aplicando operaciones de conjunto. Su costo computacional es bajo y su efecto en la calidad de la segmentación es significativo, lo que las hace especialmente útiles en Edge donde el recurso de cómputo es limitado.

El filtrado espacial aplica convoluciones con kernels específicos para suavizar (filtro gaussiano, filtro de media), realzar bordes (Sobel, Scharr, Laplaciano) o eliminar ruido impulsivo (filtro de mediana). La ecualización de histograma redistribuye los niveles de intensidad para mejorar el contraste global o local (CLAHE). Estas operaciones constituyen la etapa de preprocesamiento que acondiciona la imagen antes de la extracción de características o la inferencia con modelos de aprendizaje.

La segmentación divide la imagen en regiones con significado semántico. Los métodos clásicos incluyen segmentación por umbral (global y adaptativo), por regiones (crecimiento de regiones, watershed) y por contornos (detección de bordes con Canny seguida de agrupación). Cada método tiene supuestos distintos sobre la homogeneidad de las regiones y la nitidez de los bordes.

La extracción de características identifica puntos, bordes, regiones o descriptores que representan el contenido de la imagen de forma compacta. Los detectores de puntos clave (SIFT, SURF, ORB) encuentran regiones locales invariantes a escala y rotación. Los descriptores de forma (momentos de Hu, contornos, área, perímetro) caracterizan objetos segmentados. La transformada de Hough detecta formas geométricas en espacios de parámetros. Estas técnicas siguen vigentes como complemento o alternativa al deep learning en escenarios donde el dataset es pequeño o el cómputo disponible no admite una red neuronal.

El reconocimiento de patrones utiliza las características extraídas para clasificar objetos o regiones. Los algoritmos clásicos de aprendizaje automático — SVM, k-NN, Random Forest — operan sobre vectores de características y requieren ingeniería manual de features. Su ventaja es que funcionan con datasets pequeños y son computacionalmente livianos. Su limitación es

que la calidad del resultado depende críticamente de la calidad de la ingeniería de features, que es manual y específica del dominio.

3.3 Redes neuronales convolucionales y modelos de detección, segmentación y OCR

La contribución fundamental de las redes neuronales convolucionales (CNN) fue eliminar la necesidad de ingeniería manual de características. Una CNN aprende simultáneamente qué features extraer y cómo combinarlas para clasificar, detectar o segmentar, a partir de ejemplos etiquetados. La operación base es la convolución: un kernel de pesos aprendibles recorre la imagen produciendo un mapa de características que resalta patrones espaciales específicos. Las primeras capas aprenden bordes y texturas simples; las capas intermedias combinan esos bordes en partes de objetos; las capas profundas representan objetos completos.

La evolución arquitectónica marcó hitos que siguen siendo relevantes. LeNet (1998) demostró que las convoluciones funcionaban para reconocimiento de dígitos. AlexNet (2012) consolidó el deep learning al ganar ImageNet con margen amplio usando GPU para entrenamiento. VGG (2014) mostró que profundizar la red (16-19 capas) mejoraba el rendimiento. ResNet (2015) resolvió el problema de degradación en redes muy profundas con conexiones residuales, habilitando redes de cientos de capas con entrenamiento estable. MobileNet (2017) introdujo convoluciones separables en profundidad que redujeron drásticamente el cómputo, abriendo la puerta a la inferencia en dispositivos embebidos.

Para detección de objetos, la evolución fue de dos etapas a una etapa. Faster R-CNN (2015) generaba propuestas de región y luego clasificaba cada propuesta: preciso pero lento. YOLO (2016) reformuló la detección como un problema de regresión sobre una grilla, procesando la imagen completa en una sola pasada. Las versiones sucesivas (YOLOv5, v7, v8, v11) optimizaron velocidad, precisión y facilidad de entrenamiento hasta convertirse en el detector estándar para aplicaciones en tiempo real. RT-DETR (2023) llevó los transformers a la detección en tiempo real, eliminando el post-procesamiento NMS que YOLO todavía requiere.

Para segmentación, U-Net (2015) introdujo una arquitectura encoder-decoder con conexiones de salto que permite segmentación píxel a píxel con pocos datos de entrenamiento, convirtiéndose en referencia para inspección industrial y médica. Segment Anything (SAM, 2023) propuso un modelo fundacional de segmentación capaz de segmentar cualquier objeto a partir de un prompt (punto, caja, texto), abriendo la posibilidad de adaptación rápida a dominios nuevos sin reentrenamiento completo.

Para OCR, el patrón dominante es un pipeline de dos etapas: un detector de texto (CRAFT, EAST) localiza las regiones de texto en la imagen, y un reconocedor (CRNN, ViTSTR) transcribe los caracteres. PaddleOCR y EasyOCR empaquetan este pipeline como librerías accesibles con modelos preentrenados multilingües.

3.4 Arquitectura Edge-Fog-Cloud para visión distribuida

Los fundamentos descritos en las secciones anteriores — imagen como dato, procesamiento clásico, CNN, detección, segmentación, OCR — constituyen el qué del sistema de visión. Pero en el momento en que el sistema debe operar en un entorno real de automatización y control, emerge una segunda dimensión que las técnicas algorítmicas por sí solas no resuelven: el dónde, cómo y con qué restricciones se ejecuta la inferencia visual.

Un sistema de visión que corre en una notebook durante el desarrollo no enfrenta restricciones de latencia, ancho de banda, disponibilidad, seguridad ni escalabilidad. Un sistema de visión que corre en un nodo de borde procesando imágenes a 30 fps, publicando eventos a un broker, operando 24/7, resistiendo cortes de conectividad y protegiendo datos sensibles, enfrenta todas esas restricciones simultáneamente.

Esta transición — del algoritmo al sistema distribuido — es el punto donde la visión artificial se encuentra con las arquitecturas telecomputacionales. Los paradigmas de Edge Computing, Fog Computing y Cloud Computing definen tres perfiles de infraestructura con características opuestas y complementarias: el Edge ofrece latencia mínima con cómputo limitado; el Cloud ofrece cómputo máximo con latencia alta; el Fog opera como capa intermedia de integración, coordinación y autonomía local.

El NIST (SP 500-325) define fog como un modelo en capas que ubica nodos entre dispositivos finales y servicios centralizados, con despliegue distribuido, sensible a latencia y orientado a reducir tiempos de respuesta. El marco del OpenFog Consortium, adoptado por IEEE como estándar 1934, refuerza esa lectura con ocho pilares arquitectónicos — seguridad, escalabilidad, apertura, autonomía, RAS, agilidad, jerarquía y programabilidad — y subraya que las implementaciones reales suelen ser multinivel [22][23].

Para que la visión artificial funcione como sistema de gestión y control en un entorno de automatización, no alcanza con elegir un buen modelo de detección. Hay que resolver simultáneamente cuatro problemas: poder de cómputo (qué hardware y software se despliega en cada nivel), latencia (qué protocolos transportan la imagen o el evento entre niveles, bajo

qué restricciones temporales), inteligencia artificial (qué tipo de inferencia se ejecuta en cada nivel), y seguridad (cómo se protege el dato visual desde su captura hasta su almacenamiento).

3.5 Ejes de análisis: cómputo, latencia, inteligencia artificial y seguridad

3.5.1 Análisis por áreas telecomputacionales

Edge — Poder de cómputo. El Edge opera con recursos finitos y dedicados. Las arquitecturas se dividen en dos familias según la presencia o ausencia de sistema operativo. Los nodos con SO corren Linux embebido (Ubuntu Core, Yocto, JetPack) sobre procesadores con capacidad de inferencia visual: NVIDIA Jetson (Nano, Orin Nano, Orin NX) como familia dominante por su ecosistema CUDA y TensorRT; Rockchip RK3588 y Amlogic A311D con NPU integrada a menor costo; Qualcomm QCS6490 y Texas Instruments TDA4VM para visión industrial y automotriz; Raspberry Pi 4/5 con aceleradores externos (Coral Edge TPU, Hailo-8). Los nodos sin SO corren firmware sobre microcontroladores: ESP32-S3 con interfaz de cámara OV2640, STM32H7/N6 con DCMI y NPU, Kendryte K210/K230 con KPU para CNN, Renesas RZ/V2L con acelerador DRP-AI. Estos nodos ejecutan FreeRTOS, Zephyr o NuttX con inferencia limitada a modelos de decenas de KB con TFLite Micro o CMSIS-NN.

Edge — Latencia. La latencia tiene dos componentes: adquisición (evento físico a frame disponible, 33 ms a 30 fps por CSI) e inferencia (modelo sobre imagen: 8-15 ms en Jetson Orin Nano, 25-40 ms en Jetson Nano, 20-30 ms en RPi 5 con Hailo-8, 100-300 ms en ESP32-S3). Para transmisión al Fog: MQTT sobre TLS para eventos estructurados (payload 1-5 KB, < 10 ms en LAN), HTTP/HTTPS para imagen de evidencia (50-200 ms en LAN), RTSP/GStreamer/SRT para stream de video (30-100 ms por frame).

Edge — Inteligencia artificial. La IA en Edge cubre percepción y preprocesamiento. El stack típico: captura con OpenCV o GStreamer, preprocesamiento (resize, normalización, corrección de perspectiva), detección con YOLOv8n exportado a TensorRT u ONNX Runtime, y reconocimiento especializado (EasyOCR, PaddleOCR). Los runtimes determinan la portabilidad: ONNX Runtime con execution providers intercambiables (CUDA, OpenVINO, TensorRT, XNNPACK) es la vía más portable. Los modelos optimizados para Edge incluyen YOLOv8n/v11n (3.2M parámetros, 8.7 GFLOPs), MobileNet v2/v3, EfficientDet-Lite y NanoDet. NVIDIA DeepStream integra todo el pipeline de video analytics sobre GStreamer y TensorRT.

Edge — Seguridad. La seguridad en Edge es de hardware y firmware. Raíz de confianza en silicio: TPM 2.0 para almacenamiento seguro de claves, ARM TrustZone para aislamiento,

eFuse/OTP para flash encryption. Elementos seguros externos (ATECC608, OPTIGA Trust) almacenan claves privadas que nunca salen del chip. Secure Boot verifica la cadena de firmware desde ROM hasta kernel. TLS 1.2/1.3 obligatorio en toda conexión saliente con mbedTLS o wolfSSL en microcontroladores. Autenticación mutua TLS (mTLS) con certificados X.509 por dispositivo.

Fog — Poder de cómputo. En Fog el hardware desaparece detrás del sistema operativo. Cualquier máquina que corra Linux con Docker satisface el requisito. La decisión no es qué procesador sino cuántos cores, cuánta RAM, cuánto storage. Los formatos típicos en campo son PC industrial fanless (Advantech, OnLogic, Siemens IPC), mini PC comercial (NUC, Beelink), rack 1U compacto o VM en servidor on-premise. Si el Fog necesita re-inferencia, una GPU discreta tipo NVIDIA T4 o L4 resuelve sin cambiar la arquitectura de software. El stack incluye: broker MQTT (Mosquitto, EMQX), flujos de normalización (Node-RED, microservicios Python), base de datos local (SQLite, Redis, PostgreSQL) y opcionalmente servidor de inferencia (ONNX Runtime, Triton).

Fog — Latencia. La latencia interna (evento recibido a despacho) es 5-50 ms según complejidad de reglas. Fog-Cloud: < 5 ms en LAN corporativa, 20-100 ms en WAN con VPN, 200-500 ms en satelital/4G de baja cobertura. El buffering es la función crítica: ante caída de conectividad con Cloud, el Fog almacena eventos localmente y sincroniza al restablecer. Con SSD de 256 GB y eventos de 5 KB, el Fog puede buffear millones de eventos — días de operación sin Cloud.

Fog — Inteligencia artificial. La IA en Fog no percibe; integra, valida, correlaciona y decide. Validación semántica de eventos del Edge (formato, confianza, deduplicación). Correlación temporal con ventana de eventos recientes en Redis. Detección de anomalías operacionales con ventanas deslizantes. Re-inferencia bajo demanda con modelos más pesados cuando el Edge reporta baja confianza. Lógica de actuación: el Fog decide qué actuador activar y publica comandos en tópicos MQTT específicos.

Fog — Seguridad. La seguridad en Fog es de red, contenedores y gestión de secretos. Segmentación de red con tres segmentos (campo, gestión, administración) separados por VLAN. Firewall con iptables/nftables. ACLs en broker MQTT con mínimo privilegio por dispositivo. Docker con usuario no-root, capabilities restringidas, filesystem read-only. Docker Content Trust para firma de imágenes. Secrets management con Docker Secrets o HashiCorp Vault. Logs tamper-proof con forward inmediato al Cloud por syslog remoto sobre TLS.

Cloud — Poder de cómputo. En Cloud el poder de cómputo es elástico y el hardware completamente abstracto. Se contrata capacidad por API. Implementaciones típicas: VPS en proveedor cloud (AWS, GCP, Azure, DigitalOcean), servicios gestionados (AWS IoT Core + S3 + RDS), servidor on-premise o Kubernetes cluster. Para entrenamiento: GPU A100/H100/H200, AMD Instinct MI250/MI300, Google TPU v4/v5. Plataformas gestionadas como SageMaker, Vertex AI y Azure ML abstraen la gestión de GPU. Para almacenamiento: bases de datos relacionales o time-series para eventos, object storage para imágenes de evidencia.

Cloud — Latencia. La latencia del Cloud es la más alta del sistema, y eso es por diseño. El Cloud no decide en tiempo real: eso lo hizo el Edge. El Cloud responde en escala analítica: segundos para dashboards, horas para reentrenamiento, días para reportes. Para distribución OTA de modelos, el patrón es: reentrenamiento, firma, publicación en object storage, notificación MQTT, descarga HTTPS con verificación de firma, y carga hot-swap sin interrupción de servicio.

Cloud — Inteligencia artificial. La IA en Cloud entrena, reentrena, evalúa y distribuye. PyTorch y TensorFlow como frameworks dominantes. Ultralytics para YOLO, Hugging Face para modelos preentrenados con fine-tuning. Gestión del ciclo de vida: MLflow para tracking de experimentos, Weights & Biases para monitoreo, DVC para versionado de datasets, Label Studio y CVAT para anotación. Análisis exclusivo del Cloud: correlación histórica masiva, forecasting, detección de drift del modelo y evaluación de robustez adversarial.

Cloud — Seguridad. La seguridad en Cloud es de gobernanza, cumplimiento y protección de datos a escala. IAM con mínimo privilegio. RBAC por rol: operador, supervisor, auditor, administrador. MFA obligatoria (TOTP o FIDO2/WebAuthn). TLS terminación en load balancer, WAF contra inyección SQL/XSS/CSRF, DDoS protection. Cifrado en reposo con KMS. Cumplimiento normativo (Ley 25.326): política de retención por tipo de dato, pseudonimización de datos sensibles, purgado automático. Logging centralizado con SIEM (Wazuh, Splunk). Modelos firmados contra poisoning, model drift monitoring con alertas automáticas.

3.5.2 Análisis por características transversales

Poder de cómputo. El gradiente es claro: en Edge el hardware específico define qué modelo cabe; en Fog el SO abstrae el hardware; en Cloud se contrata capacidad elástica por API. La

portabilidad se resuelve con ONNX como formato de modelo, Docker sobre Linux para containerizar pipelines, y Wasm como horizonte emergente.

Latencia. El gradiente es inverso al cómputo: mínima en Edge, intermedia en Fog, máxima en Cloud. La latencia se compone de adquisición, inferencia, transmisión y procesamiento lógico. El buffering en Fog desacopla la operación local de la conectividad variable con Cloud.

Inteligencia artificial. La IA no hace lo mismo en cada capa: percepción en Edge con modelos optimizados y cuantizados, decisión operacional en Fog con validación y correlación, conocimiento y evolución en Cloud con entrenamiento y gestión del ciclo de vida.

Seguridad. Es el parámetro transversal estricto con presencia obligatoria en todos los nodos. El leitmotiv cambia: física y firmware en Edge (acceso físico al dispositivo), perímetro lógico y contenedores en Fog (acceso de red), gobernanza y cumplimiento en Cloud (acceso lógico a escala). La cadena se rompe por el eslabón más débil.

4. Desarrollo del Tema

4.1 Revisión de la literatura

El campo de visión artificial distribuida para automatización y control se estructura alrededor de cinco líneas de investigación convergentes. La primera es la optimización de modelos para inferencia en el borde, desde YOLO hasta RT-DETR y arquitecturas diseñadas para restricciones de memoria. La segunda es la inspección con datos escasos, donde MVTec AD y PatchCore formalizaron la detección de anomalías con entrenamiento solo sobre muestras normales. La tercera es la colaboración de inferencia End-Edge-Cloud, donde la partición óptima de una tarea visual entre dispositivo, borde y nube es dinámica. La cuarta es el OCR embebido para trazabilidad, con PaddleOCR como referencia. La quinta es la integración de visión con control industrial a través de OPC UA, MQTT/Sparkplug y gateways industriales [1]-[8].

4.2 Tecnologías y métodos

El marco teórico establecido en la sección 3 identificó los cuatro ejes de análisis aplicados a cada nivel de la infraestructura. La presente sección utiliza ese análisis como base para resolver el problema de ingeniería que el informe investiga. Ciertas tecnologías han alcanzado nivel de paradigma y pueden especificarse sin riesgo de obsolescencia: Linux como sistema operativo de referencia, Python como lenguaje dominante para visión artificial e IA, OpenCV como librería estándar, la familia YOLO como referencia de detección en tiempo real, Docker como estándar de containerización, MQTT como protocolo de mensajería IoT, GStreamer como framework de pipelines multimedia, y la arquitectura Edge-Fog-Cloud como modelo de distribución computacional.

4.3 Implementación y desarrollo

4.3.1 Descripción funcional del sistema

El sistema es una plataforma de gestión y control que utiliza la visión artificial como fuente primaria de información operacional. Es una infraestructura distribuida que observa el entorno físico a través de cámaras, interpreta lo que ve mediante inteligencia artificial, genera información estructurada a partir de esa interpretación, y la distribuye a operadores humanos, sistemas automatizados y actuadores físicos. El principio de funcionamiento es directo: la imagen entra al sistema como dato crudo y sale como decisión operacional.

4.3.2 Estación de percepción en Edge

El nodo Edge no es una cámara que transmite. Es una estación de percepción autónoma compuesta por múltiples subsistemas que cooperan para observar, interpretar, grabar, transmitir y sobrevivir.

El pipeline de adquisición se construye con GStreamer, que permite definir grafos de procesamiento multimedia con fuentes intercambiables. Una cámara CSI conectada directamente al SoC ingresa por v4l2src o nvarguscamerasrc (en Jetson, con ISP por hardware). Una cámara IP existente ingresa por rtspsrc. Una cámara USB ingresa por v4l2src. GStreamer multiplexa video y audio en el mismo pipeline, habilitando grabación audiovisual completa.

Antes de la inferencia, el frame pasa por preprocesamiento: corrección de iluminación adaptativa (CLAHE en OpenCV), normalización de color, resize al tamaño de entrada del modelo, corrección de perspectiva cuando la cámara tiene ángulo oblicuo (warpPerspective), y extracción de región de interés. En SoCs con ISP dedicado, parte de este preprocesamiento corre en hardware dedicado sin consumir CPU ni GPU.

La inferencia sigue una arquitectura en cascada: un primer modelo liviano (YOLO nano, MobileNet) detecta y localiza los objetos de interés; un segundo modelo especializado (OCR, clasificador, segmentador) procesa solamente la región detectada. La cascada evita procesar el frame completo con modelos pesados. El formato ONNX como estándar de exportación permite entrenar el modelo una vez y desplegarlo en múltiples hardware sin reentrenar.

GStreamer permite bifurcar el pipeline para grabación local: una rama va a inferencia, otra a grabación en MP4 fragmentado con codec H.264/H.265 y audio AAC u Opus. La fragmentación garantiza que un corte de energía no corrompa el archivo completo. La política de retención opera en dos niveles: grabación continua con rotación circular y retención extendida para clips marcados como incidentes.

El nodo Edge puede servir su video por tres vías complementarias: RTSP (servidor local, simple y universal pero no atraviesa NAT), WebRTC (peer-to-peer con NAT traversal mediante ICE/STUN/TURN, permite vista desde navegador sin VPN), y HLS (segmentos HTTP, mayor latencia pero máxima compatibilidad y escalabilidad con CDN).

En despliegue de campo, el nodo necesita autonomía energética: fuente principal AC/DC, batería de respaldo (UPS integrado o banco de baterías 12V), y opcionalmente panel solar con controlador de carga. Un SBC tipo Jetson Nano consume 5-10W: con batería de 12V 20Ah opera 24-48 horas en modo reducido. Un ESP32-CAM consume 0.3-0.5W: con la misma

batería opera semanas. El nodo detecta la pérdida de alimentación, conmuta a batería, reduce funcionalidad no esencial y mantiene activa la percepción.

4.3.3 Núcleo operacional en Fog

El Fog no es un servidor que recibe datos. Es el cerebro operacional del sitio: coordina, valida, correlaciona, decide y ordena actuación.

El broker de eventos (Mosquitto o EMQX en Docker) recibe eventos de todos los nodos Edge del sitio. Las ACLs restringen publicación y suscripción por identidad y tópico: cada Edge publica solo en su espacio, los consumidores se suscriben según su rol. Rate limiting protege contra saturación. Logging completo para auditoría.

El motor de correlación (Node-RED para flujos visuales o microservicio Python para lógica compleja) mantiene estado temporal en Redis. Funciones críticas: deduplicación (el mismo objeto detectado por dos cámaras genera un único evento consolidado), correlación espaciotemporal (secuencia de detecciones en puntos consecutivos reconstruye trayectoria), y detección de anomalías operacionales (frecuencia de eventos fuera de patrón normal, nodo Edge silencioso).

El motor de IA secundario implementa la cascada de inferencia distribuida: cuando el Edge reporta un evento con confianza baja, el Fog solicita el snapshot y ejecuta un modelo más pesado sobre ONNX Runtime o TensorRT si dispone de GPU local. El Fog también puede ejecutar modelos complementarios: análisis de textura, segmentación fina, anomaly detection basado en PatchCore.

El motor de actuación decide y publica comandos en tópicos MQTT específicos para cada actuador. La lógica puede ser desde una regla condicional simple hasta un motor de reglas con prioridades, cooldowns, escalamiento y supervisión humana configurable. La separación entre percepción (Edge) y actuación (actuadores suscriptos al Fog) permite escalar ambos independientemente.

La persistencia local incluye PostgreSQL para eventos estructurados, InfluxDB o TimescaleDB para métricas de sistema, Redis para cache operacional, y filesystem local con rotación para snapshots. El dashboard operacional local (interfaz web servida desde el Fog) muestra en tiempo real: eventos detectados por zona, estado de cada nodo Edge, streams de video bajo demanda, métricas de latencia y alertas activas. Esta interfaz funciona aún si el Cloud está caído.

4.3.4 Inteligencia estratégica en Cloud

El Cloud no es un servidor más grande. Es la capa que provee tres capacidades que ningún otro nivel puede ofrecer: acceso desde cualquier lugar del mundo, aprendizaje continuo sobre datos acumulados, y supervisión multi-sitio.

Los eventos consolidados del Fog llegan por MQTT sobre TLS o por API REST (HTTPS). Se almacenan en PostgreSQL o TimescaleDB para consultas operacionales. Las imágenes de evidencia se suben a object storage (S3, MinIO) y el evento contiene la referencia URI al objeto. La separación entre dato liviano (evento en base de datos) y dato pesado (imagen en object storage) permite escalar storage independientemente del cómputo.

El dashboard global es una aplicación web accesible desde cualquier navegador, con autenticación OAuth2/OpenID Connect, MFA obligatoria y RBAC por rol. Muestra vista multi-sitio, métricas agregadas, alertas activas, historial de eventos con filtros, reproducción de video grabado por evento y stream en vivo de cualquier cámara. Múltiples usuarios simultáneos con permisos diferenciados: operador, supervisor, auditor, administrador. Acceso móvil mediante Progressive Web App (PWA) con notificaciones push para alertas críticas geolocalizadas.

El pipeline de reentrenamiento opera sobre datos reales de producción: detecciones correctas, errores corregidos por operadores, casos nuevos. Estos datos se versionan (DVC), se anotan (Label Studio, CVAT), se usan para fine-tuning (PyTorch, Ultralytics), el modelo mejorado se exporta a ONNX, se firma digitalmente, se registra con métricas de validación (MLflow) y se publica para distribución OTA. La carga del modelo nuevo se hace en caliente (hot-swap): el modelo anterior sigue corriendo mientras el nuevo se carga en memoria, con conmutación atómica y cero interrupción de servicio.

La analítica avanzada incluye consultas que solo el Cloud puede resolver por escala: correlación entre múltiples sitios separados geográficamente para reconstruir trayectorias, forecasting de carga por hora/día/semana, detección de drift del modelo (si la tasa de reconocimiento cae progresivamente, se dispara reentrenamiento), y evaluación de robustez adversarial. Para despliegue pequeño, un VPS de 4 cores y 8 GB RAM basta (20-40 USD/mes). Para despliegue grande, servicios gestionados con autoscaling. La misma aplicación containerizada corre en todos los casos.

4.3.5 Interfaces de control y presentación

El sistema genera información visual procesada que llega a humanos y máquinas a través de múltiples interfaces: dashboard web (Cloud y Fog) para supervisores y operadores, aplicación de escritorio Qt/PyQt para rendering de alto rendimiento con múltiples streams, PWA móvil

para supervisores y notificaciones geolocalizadas, panel HMI industrial integrado al SCADA existente mediante OPC UA, API REST/gRPC para sistemas externos (ERP, MES), CLI para operación técnica, y alertas multicanal configurables por tipo de evento y rol (push, email, SMS, alarma sonora, señalización luminosa).

4.3.6 Actuación distribuida

El sistema cierra el bucle de control con actuadores físicos distribuidos suscriptos al bus de eventos del Fog. El actuador es el nodo más simple de la arquitectura: un microcontrolador con módulo de red suscripto a un tópico MQTT que recibe un JSON mínimo y mueve un GPIO. La separación entre percepción y actuación permite escalar ambos independientemente. El bus de eventos del Fog desacopla productores de consumidores.

4.3.7 Resiliencia y operación degradada

El sistema no tiene punto único de falla. Si el Cloud cae, el Fog continúa operando con base de datos local, reglas y actuadores. Si el Fog cae, cada nodo Edge continúa detectando, grabando y bufferizando. Si un nodo Edge cae, el Fog detecta la ausencia de heartbeat y genera alerta. MQTT con QoS 1 garantiza reintento hasta confirmación y el store-and-forward local absorbe las interrupciones de conectividad.

4.3.8 Seguridad transversal

La seguridad se implementa desde el hardware del Edge hasta la gobernanza del Cloud como componente de diseño, no como capa posterior. Cada nodo tiene certificado X.509 único, el broker requiere mTLS, las ACLs restringen por identidad y tópico, toda comunicación usa TLS 1.3, los modelos se firman antes de distribución, los logs se forwardean inmediatamente al Cloud, el dashboard requiere OAuth2+MFA, y los datos sensibles se pseudonimizan para analítica.

4.3.9 Despliegue multi-dominio

La arquitectura permanece constante entre dominios. Lo que cambia es el modelo de IA en Edge, las reglas operacionales en Fog y la semántica de los eventos. El mismo nodo Edge con cámara puede operar en cualquier dominio cargando un modelo diferente por OTA y actualizando las reglas del Fog. La infraestructura — broker, base de datos, dashboard, APIs, seguridad, actuadores — no se modifica.

4.3.10 Métricas de validación

El sistema se compromete con criterios de aceptación cuantificables: tasa de detección $\geq 95\%$ recall, tasa de reconocimiento especializado $\geq 90\%$, latencia end-to-end < 500 ms (p95),

throughput sostenido ≥ 30 eventos/minuto por nodo Edge, operación autónoma del Fog ante desconexión Cloud durante 30 minutos con 0% pérdida de eventos, sincronización post-reconexión al 100%, consumo de ancho de banda ≤ 100 Kbps por nodo, y acceso al dashboard con latencia de carga < 3 segundos.

5. Aplicación en la Industria

La arquitectura Edge-Fog-Cloud descrita en las secciones anteriores constituye una infraestructura reutilizable cuya adaptación a cada dominio requiere cambiar tres elementos: el modelo de IA en el borde, las reglas operacionales en el Fog y los actuadores físicos. En esta sección se analiza cómo se materializa esa adaptación en cuatro dominios de aplicación, identificando qué se detecta, qué modelos se aplican, cómo se cierra el bucle de control, qué empresas y proyectos lo implementan, y cuáles son los beneficios y desafíos específicos de cada uno.

5.1 Automatización industrial y control de calidad

La visión distribuida se integra en líneas de producción para inspección automatizada, reemplazando la inspección manual por percepción visual continua en línea. Los objetos de detección típicos incluyen defectos en superficies, nivel de llenado, posición de etiquetas, presencia de componentes, calidad de soldadura y contaminantes.

Los modelos aplicables al dominio se organizan en cascada según la tarea: detección con YOLO para localización de defectos y regiones de interés, segmentación con U-Net para delimitación fina de áreas afectadas, y detección de anomalías con PatchCore para defectos raros sin necesidad de ejemplos de falla — esto último es particularmente relevante en manufactura donde los eventos anómalos son infrecuentes y variables. Los actuadores del dominio incluyen rector en línea, señal al PLC para detener banda y clasificador de producto OK/NOK.

La integración con sistemas existentes se realiza mediante OPC UA hacia PLC/SCADA para el lazo de control, y MQTT/Sparkplug hacia MES para la trazabilidad de producción. El estándar OPC UA Vision, promovido por la OPC Foundation, explicita la capacidad de conectar sistemas de visión con controladores, MES, SCADA, ERP y nube sin rehacer la pirámide de automatización [9].

En casos documentados, una arquitectura con MES, visión OpenCV, clasificadores en cascada, MQTT, Node-RED y base remota reportó mejora de aproximadamente 30% en tiempos de espera y reabastecimiento. La estación de control de calidad usa visión con OpenCV, HSV y Canny para distinguir piezas correctas y defectuosas, con el nodo Fog distribuyendo carga entre nodos de campo y orquestando la redistribución cuando el uso de CPU supera umbrales operacionales [10].

Los beneficios incluyen reducción de scrap, trazabilidad completa, velocidad de inspección superior a la humana y operación 24/7. Los desafíos principales son la variabilidad de iluminación en planta, el drift del modelo por cambio de lote de producción, la integración con PLCs legacy y la certificación de seguridad funcional (IEC 62443, NIST SP 800-82) [11].

5.2 Gestión de tráfico y seguridad vial

La visión distribuida aplicada a monitoreo y control de tránsito urbano abarca dos subproblemas: control adaptativo local en intersecciones y seguimiento distribuido multiintersección. Los objetos de detección incluyen vehículos, peatones, bicicletas, motocicletas, velocidad, dirección, ocupación de carril, congestión, vehículos en contramano, infracciones y accidentes.

Los modelos aplicables incluyen detección con YOLO para identificación de vehículos, tracking con ByteTrack para conteo por línea de cruce y seguimiento de trayectoria, y OCR para lectura de patentes. Los actuadores del dominio comprenden lógica adaptativa de semáforos con tamaño de cola como parámetro de control, paneles informativos viales y alertas a autoridades de tránsito.

Para control adaptativo, un despliegue documentado con controlador basado en cámaras montadas en gabinete y cómputo completamente local redujo el retraso medio por vehículo entre 18% y 32%, permitió atender entre 50 y 200 vehículos adicionales por hora en los accesos más cargados, y siguió operando durante interrupciones de backhaul porque las decisiones se ejecutan dentro del gabinete semafórico [12].

Para seguimiento distribuido, el sistema WatchDog distribuye tareas de reidentificación entre nodos Edge dispersos geográficamente para evitar pérdida de tracking en intersecciones congestionadas, con retrasos medios de reidentificación inferiores a cuatro minutos incluso en horas pico [13]. En smart intersections, un modelo optimizado para hardware de potencia limitada mantuvo 93.64% de precisión con compresión del 97.8% en tamaño, manteniendo compatibilidad con el sistema semafórico legado [14].

Los beneficios incluyen reducción de congestión, optimización de tiempos de viaje, detección temprana de incidentes y generación de datos para planificación urbana. Los desafíos principales son condiciones climáticas adversas, reflejos nocturnos, oclusión entre vehículos, escala masiva de nodos en ciudad y privacidad de datos vehiculares.

5.3 Monitoreo ambiental y gestión de emergencias

La visión distribuida aplicada a detección de eventos ambientales y siniestros cubre humo, fuego, inundaciones, derrumbes, cambios en nivel de agua, contaminación visible y condiciones meteorológicas adversas. Los modelos aplicables incluyen clasificación binaria para detección temprana de humo y fuego, segmentación para delimitación de área afectada, y detección de cambio temporal para identificar variaciones en el entorno.

Los actuadores del dominio comprenden sirena de alerta, notificación a defensa civil, notificación push geolocalizada a dispositivos móviles en la zona afectada, y activación de protocolos de evacuación. Un desafío específico de este dominio es la operación en campo: nodos Edge alimentados por panel solar y batería, conectividad intermitente (4G, satelital) y operación offline-first con sincronización diferida.

El caso más sólido y operativo es ALERTCalifornia, programa de la University of California San Diego en coordinación con CAL FIRE. Su red supera las mil cámaras PTZ de alta definición con barridos de 360 grados cada dos minutos, visión nocturna infrarroja cercana y alcance visual de hasta 60 millas de día. El sistema de detección temprana con IA detectó más de 1.200 incendios en su primera temporada operativa, adelantándose a los reportes al 911 en más del 30% de los casos [15][16].

En paralelo, el sistema WIFIRE generó mapas predictivos de propagación en minutos desde las primeras señales de humo. Un sistema reciente sobre Raspberry Pi 5 para detección de fuego y humo alcanzó 97.98% de exactitud con 0.77 s de latencia por cuadro, demostrando que la inferencia puede empujarse cerca del sensor cuando la conectividad remota es frágil [17].

Los beneficios incluyen reducción del tiempo de respuesta ante emergencias, cobertura de zonas extensas con mínima intervención humana, y trazabilidad para análisis post-evento. Los desafíos principales son falsos positivos por nubes, neblina o vapor, operación en condiciones extremas de temperatura y humedad, autonomía energética y vandalismo de equipos en zonas remotas.

5.4 Agricultura de precisión

La visión distribuida aplicada a procesos agrícolas cubre detección de estado de cultivos, presencia de plagas, enfermedades foliares, malezas, madurez de frutos, estrés hídrico y densidad de siembra. Los modelos aplicables incluyen detección con YOLO para localización de plagas y malezas, clasificación para identificación de enfermedades por tipo, segmentación para delimitación de áreas afectadas y análisis multiespectral cuando las cámaras lo permiten.

Un aspecto distintivo de este dominio es la operación con drones como nodos Edge móviles: el dron sobrevuela el campo capturando imágenes y ejecutando inferencia local, generando mapas de detecciones geolocalizadas que el Fog correlaciona para planificar actuación. Los actuadores incluyen inyección selectiva de fumigación solo en zonas afectadas, control de riego por zona y ajuste de fertilización variable.

El sistema de pulverización selectiva de John Deere usa cámaras en la barra con módulos de visión y procesadores embebidos para identificar malezas y activar solo las boquillas necesarias. Los datos oficiales reportan ahorro medio de herbicida del 77% en barbecho sobre 75.000 acres evaluados, con detección y disparo dentro de una ventana de 200 ms. La versión avanzada reporta reducción superior al 50% en volumen aplicado frente a pulverización broadcast en maíz, algodón y soja [18][19].

Para el problema de conectividad rural, el proyecto Microsoft FarmBeats aporta una arquitectura de referencia: sistema end-to-end con sensores, cámaras y drones, conectividad local híbrida y gateway en la granja capaz de operar independientemente durante cortes de red. El despliegue reportó más de 10 millones de mediciones, 1 millón de imágenes, compresión mediana de 1000× de video aéreo, disponibilidad local durante una semana de caída de Internet, y mejora del 30% en área cubierta por vuelo [20][21].

Los beneficios incluyen reducción de agroquímicos, precisión de tratamiento, trazabilidad del proceso productivo y optimización de recursos hídricos. Los desafíos principales son variabilidad de iluminación en exterior, polvo y suciedad sobre lentes, autonomía de vuelo del dron, conectividad en zonas rurales sin cobertura y datasets específicos del cultivo local.

6. Casos de Estudio

A continuación se presentan casos de estudio concretos para cada dominio de aplicación, detallando la arquitectura desplegada, el flujo completo del dato visual y la comparación con métodos tradicionales.

6.1 Caso de estudio: Inspección visual en línea de producción

El caso industrial analizado corresponde a una transformación de un sistema de producción modular hacia una arquitectura con MES, fog computing y nube. La estación de control de calidad utiliza visión por computador con OpenCV, clasificadores en cascada, análisis HSV y detección de bordes Canny para distinguir piezas correctas y defectuosas. La estación Fog distribuye carga entre nodos FCS y un nodo maestro; la capa Cloud incorpora broker MQTT, Node-RED, base MySQL y servicios para órdenes remotas e inventario [10].

Flujo del dato visual: la cámara captura la pieza en la estación de inspección, OpenCV ejecuta preprocesamiento y clasificación localmente, el resultado (OK/NOK con confianza) se publica como evento MQTT al nodo maestro Fog, el Fog registra en base de datos local, sincroniza con el MES y ordena al actuador (rejetor o paso libre). La integración con el proceso físico se realiza mediante señales AS-i y retrofits sobre control previo, demostrando que la visión distribuida industrial puede injertarse sobre activos legacy.

Comparación con método tradicional: la inspección manual es subjetiva, lenta, sujeta a fatiga y no genera trazabilidad digital. El sistema distribuido logra inspección 100% en línea, clasificación inmediata, sincronización con stock y órdenes, y posibilidad de escalar a otras funciones OT/IT sin multiplicar interfaces propietarias. La reestructuración del proceso redujo tiempos de espera y reabastecimiento en aproximadamente 30%.

6.2 Caso de estudio: Gestión inteligente de tránsito urbano

El caso analizado corresponde a un controlador adaptativo basado en cámaras montadas en gabinete semafórico con cómputo completamente local. El sistema analiza video en tiempo real, identifica vehículos, peatones y colas, y ajusta los ciclos semafóricos según la demanda real en cada acceso [12].

Arquitectura desplegada: nodos Edge dentro del gabinete semafórico con cámara y procesador embebido, procesamiento de video e inferencia completamente local, comunicación con el centro de control de tránsito (Fog) para coordinación de corredores, y Cloud para

telemetría, auditoría y optimización de red. El sistema deja trazas por ciclo para auditoría y gobierno.

Resultados: reducción del retraso medio por vehículo entre 18% y 32%, capacidad adicional de 50 a 200 vehículos por hora en accesos cargados, y operación continua durante interrupciones de backhaul porque las decisiones se ejecutan localmente.

Comparación con método tradicional: los semáforos pretemporizados y lazos inductivos no observan geometría, colas, giros ni peatones. La visión distribuida gana porque observa contexto completo. El enfoque correcto no es reemplazar todo por visión sino usarla en cruces de mayor variabilidad, reservando niveles superiores para coordinación y optimización de red.

6.3 Caso de estudio: Detección de incendios forestales con visión distribuida

El caso corresponde al programa ALERTCalifornia de la University of California San Diego en coordinación con CAL FIRE, que opera una red de más de mil cámaras PTZ de alta definición distribuidas en puntos estratégicos [15][16].

Arquitectura desplegada: cámaras PTZ con barridos de 360° cada dos minutos, doce cuadros HD por barrido, visión nocturna infrarroja cercana y alcance de hasta 60 millas de día. La IA de detección temprana alerta con localización estimada y nivel de certeza a los 21 centros de despacho de CAL FIRE. El sistema WIFIRE genera mapas predictivos de propagación en minutos.

Resultados: más de 1.200 incendios detectados en la primera temporada operativa, adelantándose a los reportes al 911 en más del 30% de los casos. Un ejemplo oficial muestra detección a las 5:19 a.m. y primera llamada al 911 a las 6:01 a.m., con contención por debajo de un cuarto de acre gracias a la respuesta temprana.

Comparación con método tradicional: la vigilancia humana en torres y los reportes telefónicos dependen de la atención sostenida de operadores mirando múltiples pantallas. La detección asistida por IA con modelado de propagación cambia la cronología de respuesta. La validación humana sigue siendo necesaria y la infraestructura depende de línea de visión y comunicación robusta.

6.4 Caso de estudio: Fumigación selectiva con drones y visión artificial

El caso corresponde al sistema de pulverización selectiva de John Deere, que utiliza cámaras en la barra de pulverización con módulos de visión y procesadores embebidos [18][19].

Arquitectura desplegada: cámaras que escanean continuamente el lote, identificación de malezas en milisegundos con detección y disparo dentro de ventana de 200 ms, activación selectiva de boquillas ExactApply solo donde se detectó presencia de maleza. El sistema documenta lo aplicado y lo no aplicado en mapas enviados a la cuenta de operaciones del productor. La frontera Edge/Fog se ubica in-cab/in-machine, no en un microcentro de datos separado.

Resultados: ahorro medio de herbicida del 77% en barbecho sobre 75.000 acres evaluados, reducción superior al 50% en volumen aplicado en maíz, algodón y soja frente a pulverización broadcast, y aumento medio de +131 kg/ha en soja en estudios con terceros.

Para el problema complementario de conectividad rural, el proyecto Microsoft FarmBeats desplegó un sistema end-to-end con gateway en la granja capaz de operar independientemente, logrando cero downtime de estación base, compresión 1000× de video aéreo a resúmenes útiles, y disponibilidad local durante una semana completa de caída de Internet [20][21].

Comparación con método tradicional: la pulverización broadcast trata el lote como homogéneo, aplicando agroquímicos uniformemente sobre toda la superficie. La visión distribuida agrícola funciona mejor cuando la inferencia primaria y el filtrado suceden en la máquina o en el gateway, mientras la nube conserva el papel de historial, tablero de decisiones y orquestación multiestación.

6.5 Síntesis comparativa

Dominio	Edge	Fog	Cloud	Actuación	Evidencia
Industrial	Cámaras + procesamiento local	Nodo maestro, orquestación	Inventario, órdenes, respaldo	Rejector, clasificación OK/NOK	~30% mejora tiempos de espera
Tráfico	Cámaras en gabinete, inferencia on-site	Coordinación de corredores	Telemetría, auditoría	Ajuste semafórico adaptativo	18-32% reducción retraso
Ambiental	Cámaras PTZ + IA detección temprana	Centros de mando, fusión	Modelado predictivo, archivo	Despacho, evacuación, alertas	>1.200 incendios detectados
Agrícola	Visión en barra, drones, sensores	Gateway de granja resiliente	Tableros, analítica intercampana	Boquillas selectivas, riego zona	77% ahorro herbicida

Tabla 1. Síntesis comparativa de aplicación de visión distribuida Edge-Fog-Cloud en los cuatro dominios analizados.

7. Conclusión y Futuras Direcciones

El hallazgo central de esta investigación es que la arquitectura Edge-Fog-Cloud constituye una base reutilizable para sistemas de visión distribuida, pero solo si se diseña como arquitectura adaptable y no como aplicación cerrada. Lo que permanece de dominio a dominio es la partición funcional del trabajo: percepción local en el borde, coordinación operacional en capa intermedia, inteligencia estratégica en la nube y actuación distribuida sobre el entorno. Lo que se reemplaza son los modelos de percepción, las reglas de negocio y los actuadores.

En manufactura, el sistema decide buena/mala y sincroniza logística. En tráfico, recalcula ciclos semafóricos y distribuye seguimiento. En monitoreo ambiental, emite alertas y predicciones de propagación. En agricultura, abre boquillas selectivamente y genera prescripciones geolocalizadas. Esa reusabilidad parcial es lo que hace realista pensar en una base común de infraestructura y, a la vez, evita el error de pretender una plataforma universal sin adaptación sectorial.

La principal limitación transversal identificada es que no todos los dominios exponen con el mismo detalle sus costos totales, su ciberseguridad operativa o su desempeño en escenarios extremos. En industria y agricultura aparecen más datos de integración OT/IT y ahorro de insumos; en emergencias hay más evidencia de respuesta temprana que de benchmarking independiente; en tráfico abundan estudios híbridos entre despliegue y simulación.

Futuras direcciones. Las líneas de desarrollo más prometedoras incluyen: active learning para reducir la necesidad de anotación manual, federated learning para entrenar modelos sin centralizar datos sensibles, foundation models adaptados a inspección industrial y agrícola, integración con gemelos digitales para simulación y validación, OPC UA FX/TSN para reducir la distancia entre percepción y control de campo, y computación ubicua como horizonte del modelo. Las preguntas abiertas más importantes son la estandarización de actualización segura de modelos, la ubicación óptima del Fog en cada vertical, y la generación de métricas comparables de costo, precisión y resiliencia entre despliegues.

8. Referencias

- [1] J. Redmon et al., “You Only Look Once: Unified, Real-Time Object Detection,” in Proc. IEEE CVPR, 2016.
- [2] M. Sandler et al., “MobileNetV2: Inverted Residuals and Linear Bottlenecks,” in Proc. IEEE CVPR, 2018.
- [3] M. Tan et al., “EfficientDet: Scalable and Efficient Object Detection,” in Proc. IEEE CVPR, 2020.
- [4] K. Roth et al., “Towards Total Recall in Industrial Anomaly Detection,” in Proc. IEEE CVPR, 2022.
- [5] P. Bergmann et al., “MVTec AD: A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection,” in Proc. IEEE CVPR, 2019.
- [6] Y. Du et al., “PP-OCR: A Practical Ultra Lightweight OCR System,” arXiv:2009.09941, 2020.
- [7] Z. Zhou et al., “Edge Intelligence: Paving the Last Mile of AI with Edge Computing,” Proc. IEEE, vol. 107, no. 8, 2019.
- [8] W. Shi et al., “Edge Computing: Vision and Challenges,” IEEE Internet of Things J., vol. 3, no. 5, 2016.
- [9] OPC Foundation, “OPC UA for Machine Vision,” Companion Specification, 2022.
- [10] Sistema de producción modular con MES, fog computing y visión OpenCV. Arquitectura Edge-Fog-Cloud con MQTT, Node-RED, MySQL y servicios Cloud.
- [11] NIST SP 800-82 Rev. 3, “Guide to Operational Technology Security,” 2023; ISA/IEC 62443, “Security for Industrial Automation and Control Systems.”
- [12] Despliegue de controlador adaptativo basado en cámaras en gabinete semafórico con cómputo local, El Salvador City, Misamis Oriental.
- [13] WatchDog: Distributed vehicle re-identification system evaluated with urban trajectories, Shenzhen.
- [14] Smart intersection deployment, Pyeongtaek, con modelo optimizado manteniendo 93.64% precisión.
- [15] ALERTCalifornia, University of California San Diego / CAL FIRE. Red de >1.000 cámaras PTZ.
- [16] ALERTCalifornia AI wildfire detection system, primera temporada operativa: >1.200 incendios detectados.
- [17] Sistema de detección de fuego y humo sobre Raspberry Pi 5, 97.98% exactitud, 0.77 s latencia.
- [18] John Deere See & Spray™, datos oficiales: 77% ahorro herbicida en barbecho, 75.000 acres.
- [19] John Deere See & Spray™ Ultimate, reducción >50% volumen en maíz/algodón/soja.
- [20] D. Vasisht et al., “FarmBeats: An IoT Platform for Data-Driven Agriculture,” in Proc. USENIX NSDI, 2017.
- [21] Microsoft FarmBeats Project. Disponible: <https://www.microsoft.com/en-us/research/project/farmbeats/>
- [22] NIST SP 500-325, “Fog Computing Conceptual Model,” 2018.
- [23] IEEE 1934-2018, “Standard for Adoption of OpenFog Reference Architecture.”
- [24] Siemens Industrial Edge, OPC UA Vision integration documentation.
- [25] Ultralytics, “YOLOv8 Documentation,” 2023-2025. Disponible: <https://docs.ultralytics.com/>

- [26] Y. Zhao et al., “RT-DETR: DETRs Beat YOLOs on Real-time Object Detection,” arXiv:2304.08069, 2023.